

DOC-005: INFRASTRUCTURE SIZING QUESTIONNAIRE

UFOSI — Universal Financing Optimized Syariah Intelligent-assistant

A. METADATA & GOVERNANCE CONTROL

Parameter Tata Kelola	Deskripsi & Identifikasi Dokumen
Kode Dokumentasi	DOC-005
Fase Tata Kelola	Technology Architecture Phase — SDLC Mapping: Capacity Sizing Verification
Versi Master	v1.2.0 — Updated: 04 June 2026
Status Dokumen	☒ Draft ☐ Under Review ☐ Approved

B. ACCOUNTABILITY & READINESS MATRIX

Peran Tata Kelola	Aktor / Pemangku Kepentingan	Uraian Tanggung Jawab Operasional & Kesiapan
Document Owner	IT Infrastructure Architect / IT Operational Team	Melakukan validasi beban komputasi virtual, menetapkan alokasi VM host, memastikan resource Kubernetes/K3s mencukupi, dan merencanakan ekspansi storage jangka pendek guna memfasilitasi Demo Day proyek UFOSI.
Target User Input	Lead Developer / Dev Stream	Wajib memberikan estimasi kebutuhan core vCPU, RAM, batasan IOPS disk database, alokasi penyimpanan file PDF rekening koran yang di-upload, dependency aplikasi, serta kebutuhan runtime container.
Solution Architect	Solution Architect / Architecture Stream	Memastikan kecocokan ukuran resource terhadap pola ekstraksi microservices container yang dirancang, termasuk frontend, backend API, AI/OCR engine, database, dan monitoring stack.
IT Operations Team	IT Operations / Platform Team	Menyediakan environment VM, Docker/K3s, namespace aplikasi, persistent storage, monitoring, backup, serta melakukan validasi performa dasar sebelum demo.
QA / UAT Representative	QA Tester / UAT Team	Membantu melakukan simulasi upload dokumen, uji concurrent user ringan, validasi response time aplikasi, dan verifikasi bahwa sizing cukup untuk skenario demo.

C. STRATEGIC PURPOSE / TUJUAN OPERASIONAL

Dokumen ini berfungsi sebagai acuan teknis perencanaan kapasitas komputasi atau Capacity Management untuk proyek UFOSI, yaitu Universal Financing Optimized Syariah Intelligent-assistant.

UFOSI memproses dokumen keuangan berupa rekening koran melalui proses OCR dan AI parsing. Karena workload tersebut berpotensi menggunakan CPU, memori, storage, dan I/O database secara intensif, penentuan dimensi performa mesin virtual menjadi hal penting sejak awal. Sizing yang tidak tepat dapat menyebabkan bottleneck, container restart, kehabisan memori server, OOM Killer, lambatnya proses ekstraksi dokumen, atau gangguan saat demo di hadapan manajemen.

Poin utama dokumen ini adalah memitigasi risiko kekurangan resource pada runtime Docker/Kubernetes, memastikan kelancaran demo pemrosesan dokumen, menyediakan baseline kapasitas environment UAT/Staging, serta menstandarisasi kebutuhan resource untuk deployment jangka pendek.

D. CONTENTS & QUESTIONNAIRE FOR DEVELOPER

Bagian ini wajib dilengkapi secara rinci oleh Tim Pengembang atau Development Stream dan divalidasi bersama IT Operations.

1. Informasi Lingkungan Deployment

Deployment Environment

Parameter Lingkungan	Detail Pengisian oleh Developer Team
Target Lingkungan Deploy	☐ Development ☒ UAT / Staging — Untuk kebutuhan demo tugas ☐ Production ☐ DR Site
Arsitektur Aplikasi	☐ Monolith ☒ Microservices — Docker Container ☐ Serverless
Platform Orkestrasi	Kubernetes ringan menggunakan K3s pada VM Ubuntu.
Model Deployment	Container-based deployment untuk frontend, backend API, AI/OCR service, PostgreSQL database, dan monitoring stack.
Target Namespace	Namespace aplikasi: ufosi. Namespace monitoring: monitoring.
Target Akses	Internal network / NodePort untuk kebutuhan UAT dan demo. Tidak internet-facing.
Tujuan Environment	Menjalankan demo end-to-end proses upload rekening koran, ekstraksi data, analisis, penyimpanan hasil, serta monitoring dasar.

2. Estimasi Kebutuhan Komputasi & Resource

Compute & Storage Sizing

Mohon definisikan estimasi kebutuhan resource VM / Container Host untuk menjalankan engine ekstraksi dan database UFOSI.

Spesifikasi Resource	Estimasi Kebutuhan Sistem
CPU Requirement / vCPU	4 Cores sebagai baseline minimum demo/UAT. Rekomendasi Ops untuk AI Engine: 4–8 vCPU. Catatan: Baseline demo berjalan pada single-node K3s di VM 1. Rekomendasi Ops untuk UFOSI adalah minimal 4 vCPU karena host menjalankan beberapa workload secara bersamaan, yaitu frontend, backend API, AI/OCR service, PostgreSQL, Prometheus, dan Grafana.
Memory Requirement / RAM	8 GB RAM sebagai baseline minimum demo/UAT. Rekomendasi Ops untuk AI Parser: 8–16 GB RAM. Catatan: RAM digunakan untuk menjalankan OS, Kubernetes/K3s, container aplikasi UFOSI, database PostgreSQL, monitoring stack, cache runtime, dan proses parsing dokumen. Untuk simulasi yang lebih stabil, 16 GB direkomendasikan jika tersedia.
Kebutuhan Storage Aplikasi & OS	40 GB. Tipe Disk: ☐ HDD ☐ SAS ☒ SSD/NVMe. Catatan: Storage digunakan untuk OS, Docker/container image, K3s/containerd image, manifest Kubernetes, log sistem, evidence, package dependency, temporary file, dan konfigurasi aplikasi.
Kebutuhan Disk Khusus Data / PDF Record	10 GB volume penyimpanan file raw scanning nasabah SME. Catatan: Digunakan untuk penyimpanan file dummy rekening koran, hasil parsing, file temporary upload, dan buffer pengujian demo. Untuk fase demo disarankan hanya menggunakan dummy/synthetic data.
Total Storage Minimum Rekomendasi	50 GB minimum — 40 GB untuk OS dan aplikasi, 10 GB untuk data dokumen dan buffer. Rekomendasi aman: 80 GB apabila host juga menyimpan backup database, log monitoring, evidence deployment, dan image container tambahan.
Karakteristik IOPS Storage Database	☐ Low — kurang dari 500 IOPS ☒ Medium — 500 sampai 2000 IOPS ☐ High — lebih dari 2000 IOPS
Persistent Volume Requirement	Dibutuhkan untuk PostgreSQL dan folder data aplikasi agar data tidak hilang saat container/pod restart.
Backup Storage Requirement	Minimal tersedia ruang tambahan untuk backup database PostgreSQL sebelum deployment besar, maintenance, atau demo.
Resource Limit Container	Disarankan menetapkan request/limit CPU dan memory per service untuk mencegah satu container menghabiskan seluruh resource node.

3. Karakteristik Beban Transaksi & Trafik

Traffic & Transaction Metrics

Parameter Beban Trafik	Proyeksi Volume Metrik
Estimasi Transaksi Harian / Demo	10–30 berkas rekening koran diekstraksi per hari selama fase demo/UAT.
Average TPS / Transaction Per Second	1 TPS pada kondisi beban normal.
Peak TPS / Beban Puncak Demo	2–5 TPS pada kondisi pemrosesan simultan saat pengujian fungsional atau demo terbatas. Catatan: Kondisi pemrosesan simultan dibatasi untuk menjaga kestabilan single-node K3s dan menghindari spike resource pada AI/OCR service.
Peak Concurrent User	Estimasi 5–10 concurrent users untuk skenario UAT/demo terbatas.
Rata-rata Ukuran Dokumen Diupload	[] kurang dari 5 MB [v] 5–20 MB [] lebih dari 20 MB Batas Max Upload: 20 MB per file untuk fase demo/UAT.
Pola Trafik	Trafik bersifat burst saat demo, terutama ketika user melakukan upload file, proses OCR, parsing, dan penyimpanan hasil ekstraksi.
Risiko Trafik	Jika beberapa dokumen besar diproses bersamaan, AI/OCR service berpotensi mengalami lonjakan penggunaan CPU/RAM.
Mitigasi Trafik	Batasi jumlah concurrent upload, gunakan ukuran file dummy yang terkendali, dan lakukan monitoring CPU/RAM pod saat demo.

4. Proyeksi Pertumbuhan Data Jangka Pendek

Growth Projection

Periode Proyeksi	Estimasi Penambahan Ukuran Ruang Disk
Growth Selama Fase Evaluasi / 1 Bulan	[v] Alokasi Tetap Berjalan / Fixed Buffering [] Estimasi Penambahan Kustom: GB Catatan: Disediakan buffer tetap untuk file dummy, hasil parsing, database, log aplikasi, backup ringan, dan evidence deployment selama fase demo/UAT.
Estimasi Penambahan File Upload	10–30 dokumen per hari dengan ukuran rata-rata 5–20 MB. Jika tidak dilakukan purge, kebutuhan storage dapat meningkat cepat.
Estimasi Penambahan Database	Relatif rendah pada fase demo, karena database hanya menyimpan metadata, status proses, dan hasil parsing terbatas.
Estimasi Penambahan Log	Sedang, tergantung level logging aplikasi. Debug log harus dikurangi sebelum demo agar tidak memenuhi disk.
Strategi Kontrol Growth	Terapkan file retention, purge file temporary, rotasi log, dan backup terjadwal terbatas.
Rekomendasi Retensi Demo	File upload temporary dan hasil parsing dummy dibersihkan setelah evaluasi selesai atau maksimal 7 hari.

5. Ketergantungan Perangkat Lunak Lingkungan Host

Software Dependencies

Spesifikasi Platform	Kebutuhan Dasar Sistem
Rekomendasi OS Base Image Host	[v] Ubuntu Server LTS [] RedHat Enterprise Linux / RHEL [] Rocky Linux
Engine Database / State Store	[v] PostgreSQL [] MySQL [] MongoDB [v] Redis — untuk caching antrian dokumen Catatan: Redis dicatat sebagai opsi caching/antrian dokumen untuk pengembangan lanjutan. Pada deployment Day 8/Day 9, database aktual yang sudah berjalan adalah PostgreSQL.
Kebutuhan Pustaka Tambahan / Host	[] Tesseract OCR Native Lib [] Nvidia CUDA Driver Support [v] Docker Engine & Docker Compose Only Catatan: AI/OCR berjalan sebagai container image, sehingga host tidak membutuhkan instalasi Tesseract OCR atau CUDA secara langsung pada fase demo.
Container Runtime	Docker/containerd melalui K3s.
Orchestration Tool	K3s untuk menjalankan pod, deployment, service, namespace, dan self-healing dasar.
Monitoring Tool	Prometheus dan Grafana untuk monitoring CPU, memory, pod status, dan availability

Spesifikasi Platform	Kebutuhan Dasar Sistem
	service.
Backup Tool	pg_dump untuk backup PostgreSQL sebelum maintenance, re-deployment, atau pembersihan data.
Network Utility	curl, kubectl, docker, ss/netstat, dan tools dasar Linux untuk validasi service dan troubleshooting.
Automation Support	Terraform pada VM terpisah untuk kebutuhan dokumentasi/simulasi network automation dan topology evidence.

6. Rekomendasi Pembagian Resource per Komponen

Komponen	Estimasi Resource Minimum	Catatan Operasional
Frontend	0.25–0.5 vCPU, 256–512 MB RAM	Beban relatif ringan, melayani UI dan static asset.
Backend API	0.5–1 vCPU, 512 MB–1 GB RAM	Menangani request user, integrasi ke database, dan komunikasi dengan AI/OCR service.
AI/OCR Service	1–2 vCPU, 2–4 GB RAM	Komponen paling berat karena memproses dokumen dan parsing. Perlu dipantau saat upload file besar.
PostgreSQL	0.5–1 vCPU, 1–2 GB RAM	Menyimpan metadata, hasil parsing, dan konfigurasi aplikasi. Membutuhkan persistent volume.
Prometheus	0.5 vCPU, 512 MB–1 GB RAM	Menyimpan metrics monitoring. Retensi perlu dibatasi agar disk tidak cepat penuh.
Grafana	0.25 vCPU, 256–512 MB RAM	Visualisasi dashboard monitoring. Beban ringan.
K3s/System Overhead	0.5–1 vCPU, 1–2 GB RAM	Overhead node, kubelet, container runtime, service networking, dan OS.

7. Validasi Kapasitas Minimum Sebelum Demo

Area Validasi	Command / Cara Validasi	Expected Result
CPU & Memory Node	kubectl top nodes atau free -h	Penggunaan CPU dan RAM masih memiliki headroom sebelum demo.
Status Pod	kubectl get pods -n ufosi	Seluruh pod UFOSI berada pada status Running.
Status Monitoring	kubectl get pods -n monitoring	Prometheus dan Grafana Running.
Disk Usage	df -h	Disk tidak berada di atas 80% usage.
Service Exposure	kubectl get svc -n ufosi	Frontend dan backend service memiliki NodePort/internal access sesuai kebutuhan.
Backend Healthcheck	curl http://<IP-SERVER>:<BACKEND-NODEPORT>/api/v1/health	Response HTTP 200 OK.
Database Backup	pg_dump atau command backup sesuai prosedur	Backup berhasil dibuat sebelum demo atau perubahan besar.
Log Error	kubectl logs pada pod terkait	Tidak ada error kritis berulang, OOMKilled, CrashLoopBackOff, atau disk full.

8. Risiko Kapasitas & Mitigasi

Risiko	Dampak	Mitigasi
RAM tidak cukup saat proses AI/OCR	Pod restart, OOMKilled, proses parsing gagal	Gunakan RAM minimal 8 GB, batasi concurrent upload, dan monitoring resource saat demo.
CPU overload saat beberapa file diproses	Response lambat dan demo tidak stabil	Batasi peak TPS, gunakan file dummy ukuran sedang, dan hindari proses simultan berlebihan.
Disk penuh karena image, log, dan file upload	Deployment gagal, database tidak bisa menulis data	Bersihkan image tidak terpakai, rotasi log, purge file upload temporary, dan monitor df -h.
Database I/O lambat	Query lambat dan hasil parsing terlambat tersimpan	Gunakan SSD/NVMe dan karakteristik IOPS medium.
Monitoring stack memakan resource terlalu besar	Resource aplikasi utama terganggu	Batasi retensi Prometheus dan pantau penggunaan memory monitoring namespace.
Tidak ada backup sebelum perubahan	Risiko kehilangan data saat maintenance	Jalankan backup database sebelum redeploy, cleanup, atau demo besar.
Single-node K3s menjadi bottleneck	Semua workload terdampak jika node bermasalah	Untuk production, pisahkan node aplikasi, database, dan monitoring. Untuk demo, pastikan VM stabil.

9. Rekomendasi Final Sizing UFOSI

Kategori	Rekomendasi Final
Environment	UAT / Staging untuk Demo Day
Architecture	Microservices berbasis Docker Container di atas K3s
Minimum vCPU	4 vCPU
Recommended vCPU	4–8 vCPU
Minimum RAM	8 GB
Recommended RAM	16 GB apabila tersedia
Minimum Storage	50 GB
Recommended Storage	80 GB SSD/NVMe
Database	PostgreSQL 16
Optional Cache/Queue	Redis untuk pengembangan lanjutan
Monitoring	Prometheus dan Grafana
File Upload Limit	20 MB per file untuk fase demo/UAT
Average TPS	1 TPS
Peak TPS	2–5 TPS terbatas
Concurrent User Demo	5–10 user
Data Retention Demo	File temporary dibersihkan maksimal 7 hari setelah evaluasi
Network Exposure	Internal only, tidak internet-facing

10. Kesimpulan Sizing

Berdasarkan karakteristik aplikasi UFOSI, workload utama berada pada proses upload dokumen, OCR/AI parsing, penyimpanan hasil ekstraksi, dan monitoring runtime container. Untuk kebutuhan UAT/Staging dan Demo Day, baseline minimum yang direkomendasikan adalah 4 vCPU, 8 GB RAM, dan total storage minimal 50 GB berbasis SSD/NVMe.

Namun, untuk menjaga stabilitas demo dan menghindari risiko OOMKilled pada service AI/OCR, konfigurasi yang lebih aman adalah 4–8 vCPU, 16 GB RAM, dan 80 GB SSD/NVMe. Karena deployment berjalan pada single-node K3s, penggunaan resource harus dipantau secara aktif, terutama pada pod AI/OCR, PostgreSQL, dan monitoring stack.

Dokumen DOC-005 ini menjadi dasar validasi capacity sizing bagi IT Operations, Developer Team, Solution Architect, dan QA/UAT sebelum aplikasi UFOSI dijalankan pada skenario demo atau staging.